

第5章

线性判别函数

Linear Discriminant Functions

向 世 明

smxiang@nlpr.ia.ac.cn

<http://www.escience.cn/people/smxiang/index.html>

时空数据分析与学习课题组 (STDAL)

中科院自动化研究所 模式识别国家重点实验室

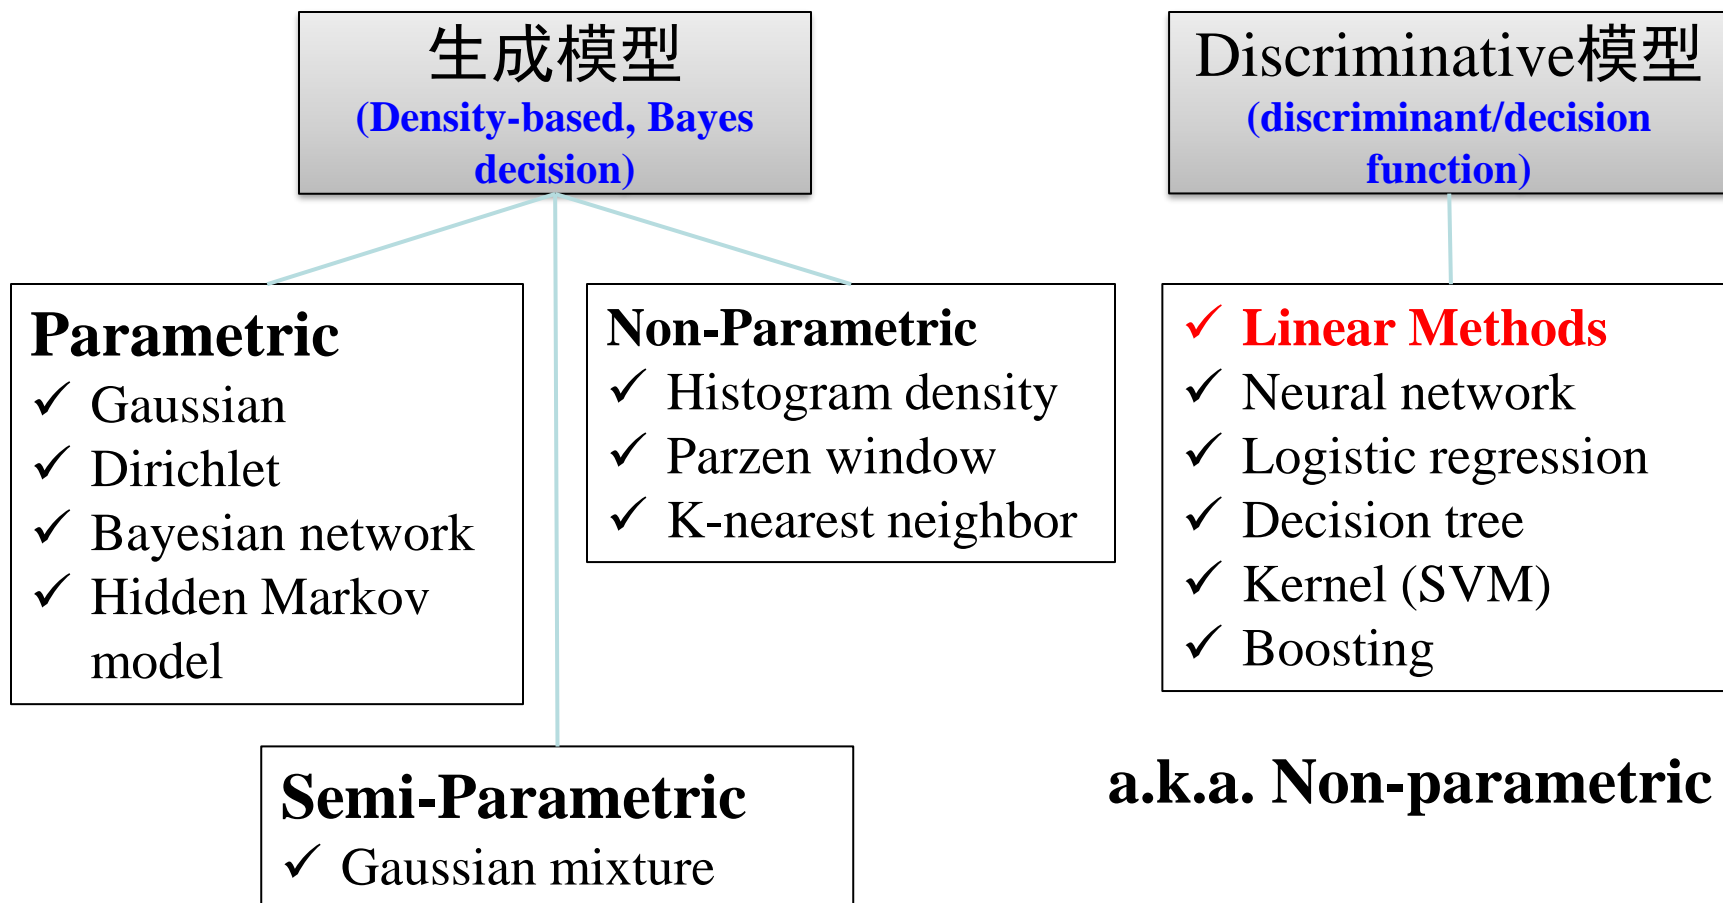
助教: 张明亮(zhangmingliang2018@ia.ac.cn)

程真(chengzhen2019@nlpr.ia.ac.cn)

张姣(zhangjiao2019@ia.ac.cn)

5.1 引言

统计模式识别方法



5.1 引言

- 前面几章主要内容回顾：
 - 贝叶斯决策理论
 - 概率密度估计——函数已知情形时，参数估计
 - 非参数估计——密度函数未知
- 本章主要任务：
 - 假定用于分类的判别函数的参数形式已知，直接从样本来估计判别函数的参数。
 - 优点：
 - 不需要有关概率密度函数确切的参数形式。

5.1 引言

- 模式分类的途径
 - 估计类条件概率密度函数
 - 利用贝叶斯公式求出后验概率，然后决策
 - 核心步骤：概率密度估计（参数估计和非参数估计）
 - 直接估计后验概率
 - 不需要估计类条件概率密度函数
 - K-近邻分类器
 - 直接计算判别函数
 - 不需要估计类条件概率密度函数
 - 直接找到可用于分类的判别函数

5.1 引言

- 回顾Bayes分类器

- 已知：类先验概率 $p(\omega_i)$ 和类条件密度函数 $p(\mathbf{x}|\omega_i)$
- 任务：估计一个决策函数，借此进行分类
- 主要方法：参数估计与非参数估计
- 特点：需要大量的样本，需要知道某些概率及其形式

- 可否利用样本直接设计分类器？

- 方法分类

- 线性判别函数、支持向量机、Fisher线性判别函数
- 广义线性判别函数、非线性判别函数、核学习机

5.1 引言

- 本章学习判别函数的基本技术路线：
 - 假定有 n 个 d 维空间中的样本，每个样本的类别标签已知，且一共有 c 个不同的类别。
 - 假定判别函数的形式已知，采用样本来训练判别函数的参数，即寻找一个判别函数。
 - 对于给定的新样本 $\mathbf{x} \in \mathbb{R}^d$ ，判定它属于 $\omega_1, \omega_2, \dots, \omega_c$ 中的哪个类别。


5.1 引言

- 基于判别函数的分类器

- 采用已知类别标签的训练样本进行学习，获得若干个代数界面，这些界面将样本所在的空间分成若干个相互不重叠的区域。每个区域包含属于同一类的样本。
- 表示界面的函数称为判别函数。
- 判别函数是分类器最常用的表述形式。

5.1 引言

- 判别函数：判定样本属于哪一个类别区域的函数



图中，边界线可构造为一个判别函数

5.1 引言

- 基于判别函数的判别准则

- 对于 c 类分类问题（线性机器）：

- 设 $g_i(\mathbf{x})$, $i = 1, 2, \dots, c$, 表示每个类别对应的判别函数
- 决策规则：
 - 如果 $g_i(\mathbf{x}) > g_j(\mathbf{x}), \forall j \neq i$, 则 \mathbf{x} 被分为第 ω_i 类。

- 对于两类分类问题


- 可以只用一个判别函数： $g(\mathbf{x}) = g_1(\mathbf{x}) - g_2(\mathbf{x})$
- 判别准则： $g(\mathbf{x}) > 0$, 分为第一类；否则为第二类。

比如： $g(\mathbf{x}) = p(\omega_1 | \mathbf{x}) - p(\omega_2 | \mathbf{x})$, $g(\mathbf{x}) = \log \frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} + \log \frac{p(\omega_1)}{p(\omega_2)}$


5.1 引言

- 线性可分

- 对于 n 个 d 维空间中的样本 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ ，假定这些样本来自于两个类别 ω_1 或 ω_2 。如果存在一个线性判别函数能对这些样本正确地分类，则称这些样本是线性可分的；否则是线性不可分的。



线性可分



线性不可分

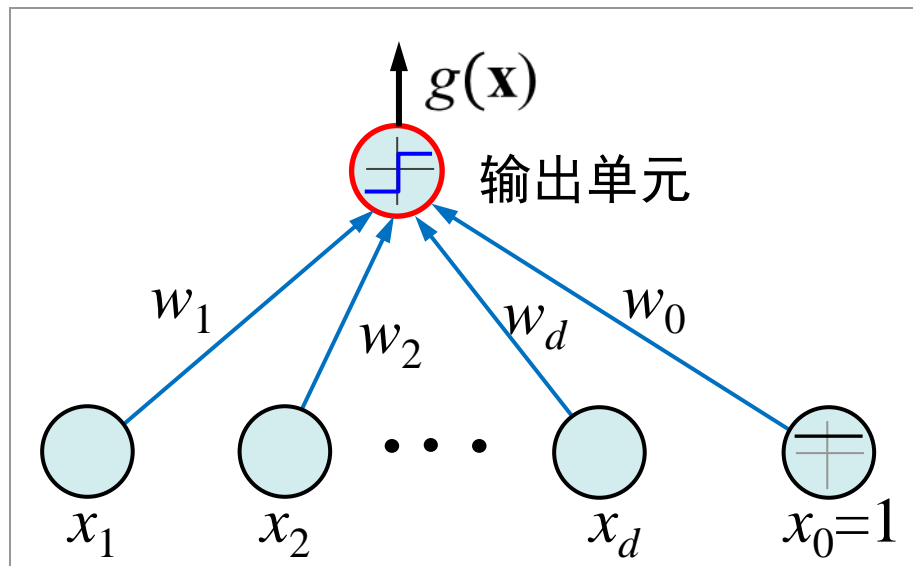
5.2 线性判别函数与决策面

- 线性判别函数（基本形式）：

$$g(\mathbf{x}) = \underset{\substack{\uparrow \\ \text{权重向量}}}{\mathbf{w}^T} \mathbf{x} + \underset{\substack{\uparrow \\ \text{偏移(阈值)}}}{w_0} \quad (1)$$

- 两类情形的决策规则：

$$\begin{cases} \mathbf{x} \in \omega_1, & \text{if } g(\mathbf{x}) > 0 \\ \mathbf{x} \in \omega_2, & \text{if } g(\mathbf{x}) < 0 \\ \text{uncertain}, & \text{if } g(\mathbf{x}) = 0 \end{cases}$$




线性分类器（神经网络描述）

5.2 线性判别函数与决策面

- 两类情形的决策面

- $g(\mathbf{x})=0$ 定义了一个决策面，它是类 ω_1 和 ω_2 的分界面。
- $g(\mathbf{x})=0$ 是一个超平面，记为 H 。位于该平面的任意向量与 \mathbf{w} 垂直：
 - 如果 \mathbf{x}_1 和 \mathbf{x}_2 位于该超平面内，于是有：

$$g(\mathbf{x}_1) - g(\mathbf{x}_2) = \mathbf{w}^T(\mathbf{x}_1 - \mathbf{x}_2) = 0$$




5.2 线性判别函数与决策面

- 两类情形的决策面

- 对于任意样本 \mathbf{x} ，将其向决策面内投影，并写成两个向量之和：

$$\mathbf{x} = \mathbf{x}_p + r \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

其中， \mathbf{x}_p 为 \mathbf{x} 在超平面 H 上的投影， r 为点 \mathbf{x} 到超平面 H 的代数距离。如果 \mathbf{x} 在超平面正侧，则 $r > 0$ ；反之 $r < 0$ 。



5.2 线性判别函数与决策面


- 两类情形的决策面

– 注意 $g(\mathbf{x}_p) = 0$, 于是有:

$$\begin{aligned} g(\mathbf{x}) &= \mathbf{w}^T \left(\mathbf{x}_p + r \frac{\mathbf{w}}{\|\mathbf{w}\|} \right) + w_0 \\ &= r \|\mathbf{w}\| \end{aligned}$$

$$\Rightarrow r = \frac{g(\mathbf{x})}{\|\mathbf{w}\|}$$

此外, 可得坐标原点到超平面的
距离为: $w_0 / \|\mathbf{w}\|$




5.2 线性判别函数与决策面

- 多类情形 ($c > 2$)—采用多个两类分类器
 - One-vs-all: 逐一与所有的其它类进行配对, 可以构造 c 个两类分类器。
 - One-vs-one: 两两(类-类) 配对, 可以构造 $c(c-1)/2$ 个两类分类器。
 - 逐步一对多: 将 c 类问题逐步转化个两类分类问题。第一个分类器将其中一个类样本与其余各类样本分开, 接着在其余各类中设计第二个分类器, 直至仅剩下两个分类器为止。
- 多个两类分类器:
$$g_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + w_{i0}, \quad i = 1, 2, \dots, k$$

5.2 线性判别函数与决策面


- 多类情形: One-vs-all



存在不确定区域


5.2 线性判别函数与决策面

- One vs all (4类):



5.2 线性判别函数与决策面

- 多类情形: one-vs-one



5.2 线性判别函数与决策面

- 多类情形—线性机器

- 考虑one-vs-all情形，构建 c 个两类线性分类器：

$$g_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + w_{i0}, \quad i = 1, 2, \dots, c$$

- 对样本点 \mathbf{x} ，可以采用如下更简洁的决策规则：

对 $j \neq i$ ，如果 $g_i(\mathbf{x}) > g_j(\mathbf{x})$ ， \mathbf{x} 则被分类 ω_i 类；否则不决策




$$\mathbf{x} \in \omega_i, \quad g_i(\mathbf{x}) = \max_{j=1,2,\dots,c} g_j(\mathbf{x})$$

线性机器将样本空间分为 c 个可以决策的区域 R_1, \dots, R_c

5.2 线性判别函数与决策面


- 多类情形—线性机器：（变成“最大”决策）



线性机器将样本空间分为 c 个可以决策的区域 R_1, \dots, R_c

5.2 线性判别函数与决策面


- 线性机器的决策面：一个例子（One-vs-one）



5.2 线性判别函数与决策面

- 线性机器决策面：例子


- 可以多达 $c(c-1)/2$ 个决策边界（有些可能可以删除）！



5.2 线性判别函数与决策面

- 线性决策面优缺点：

- 所有的决策区域都是凸的 — 便于分析
- 所有的决策区域都是单通连的 — 便于分析
- **凸决策区域**：限制分类器的灵活性和精度
- **单通连区域**：不利于复杂分布数据的分类（比如：分离的多模式分布）



5.3 广义线性判别函数

- 线性判别函数形式简单，计算方便，且已被充分研究。
人们期望将其推广至非线性判别函数。

一种有效的途径是将原来的数据点 \mathbf{x} 通过一种适当的**非线性映射**将其映射为新的数据点 \mathbf{y} ，从而在新的数据空间内可以应用线性判别函数方法。

- 线性情形

$$g(\mathbf{x}) = w_0 + \sum_{i=1}^d w_i x_i, \quad \text{其中, } \mathbf{x} = [x_1, x_2, \dots, x_d]^T$$

- 推广

– 多项式判别函数，比如二次推广：

$$g(\mathbf{x}) = w_0 + \sum_{i=1}^d w_i x_i + \sum_{i=1}^d \sum_{j=1}^d w_{ij} x_i x_j$$

$$= \sum_{i=1}^{\hat{d}} a_i y_i(\mathbf{x}) \quad (\text{记为})$$

$$y_1(\mathbf{x}) = 1;$$

$$y_2(\mathbf{x}) = x_1;$$

$$y_3(\mathbf{x}) = x_2;$$

...

$$y_{d+1}(\mathbf{x}) = x_d;$$

$$y_{d+2}(\mathbf{x}) = x_1^2;$$

$$y_{d+3}(\mathbf{x}) = x_1 x_2;$$

...

$$y_{\frac{(d+1)(d+2)}{2}}(\mathbf{x}) = x_d^2;$$

1. 共有 $(d+1)(d+2)/2$ 个系数待估计 ($w_{ij} = w_{ji}$)
2. $g(\mathbf{x})=0$ 为决策面，它是一个二次超曲面

5.3 广义线性判别函数

• 一般情形
$$g(\mathbf{x}) = \sum_{i=1}^{\hat{d}} a_i y_i(\mathbf{x})$$
 $y_i(\mathbf{x})$: 变换函数

令 $\mathbf{a} = [a_1, a_2, \dots, a_{\hat{d}}]^T$, $\mathbf{y} = [y_1, y_2, \dots, y_{\hat{d}}]^T$ 可以简写为:


$$g(\mathbf{x}) = \mathbf{a}^T \mathbf{y}$$

1. \mathbf{a} 为**广义权重向量**, \mathbf{y} 是经由 \mathbf{x} 所变成的新数据点。
2. 广义判别函数 $g(\mathbf{x})$ 对 \mathbf{x} 而言是非线性的, 对 \mathbf{y} 是线性的。
3. $g(\mathbf{x})$ 对 \mathbf{y} 是齐次的, 意味着决策面通过新空间的坐标原点。且任意点 \mathbf{y} 到决策面的代数距离为 $\mathbf{a}^T \mathbf{y} / \|\mathbf{a}\|$ 。
4. 当新空间的维数足够高时, $g(\mathbf{x})$ 可以逼近任意判别函数。
5. 但是, 新空间的维数远远高于原始空间的维数 d 时, 会造成维数灾难问题。

5.3 广义线性判别函数

- 例子1

- 设有一维样本空间 X ，我们期望如果 $x < -1$ 或者 $x > 0.5$ ，则 x 属于第一类 ω_1 ；如果 $-1 < x < 0.5$ ，则属于第二类 ω_2 ，请设计一个判别函数 $g(x)$ 。



5.3 广义线性判别函数

• 例子1


- 设有一维样本空间 X ，我们期望如果 $x < -1$ 或者 $x > 0.5$ ，则 x 属于第一类 ω_1 ；如果 $-1 < x < 0.5$ ，则属于第二类 ω_2 ，请设计一个判别函数 $g(x)$ 。
- 决策函数： $g(x) = (x-0.5)(x+1)$
- 决策规则： $g(x) > 0$, x 属于 ω_1 ； $g(x) < 0$, x 属于 ω_2

$$\begin{aligned} g(x) &= (x-0.5)(x+1) \\ &= -0.5 + 0.5x + x^2 \\ &= a_1 + a_2x + a_3x^2 \end{aligned}$$

映射关系 $\Rightarrow \mathbf{y} = \begin{pmatrix} 1 \\ x \\ x^2 \end{pmatrix} \doteq \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix}$

5.3 广义线性判别函数

- 例子1



• 例子2

– 对线性判别函数采用齐次增广表示

• 此时，增广样本向量 \mathbf{y} 与增广权重向量 \mathbf{a} 如下：

$$\mathbf{y} = \begin{pmatrix} 1 \\ \mathbf{x} \end{pmatrix} = [1 \quad x_1 \quad \cdots \quad x_d]^T, \quad \mathbf{a} = \begin{pmatrix} w_0 \\ \mathbf{w} \end{pmatrix} = [w_0 \quad w_1 \quad \cdots \quad w_d]^T$$

– 线性判别函数的齐次简化： $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0 = \mathbf{a}^T \mathbf{y}$

– Y空间中任意一点 \mathbf{y} 到 H 的距离为： $r = \frac{g(\mathbf{x})}{\|\mathbf{a}\|} = \frac{\mathbf{a}^T \mathbf{y}}{\|\mathbf{a}\|}$

线性齐次空间增加了一个维度，仍可保持欧氏距离不变，分类效果与原来的决策面相同。但分类面将过坐标原点，对于某些分析，将具有优势。

上述增广样本向量将在后面的讨论中经常使用。

5.4 感知准则函数

- 线性可分性

- 现有 n 个样本: $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n$, 这些样本来自于两个类别 ω_1 或 ω_2 。
- 任务: 寻找一个线性判别函数 $g(\mathbf{x}) = \mathbf{a}^T \mathbf{y}$, 使对这 n 个样本的错分概率最小。
- 如果存在一个权向量 \mathbf{a} , 对所有 $\mathbf{y} \in \omega_1$, 均有 $\mathbf{a}^T \mathbf{y} > 0$, 且对所有 $\mathbf{y} \in \omega_2$, 均有 $\mathbf{a}^T \mathbf{y} < 0$, 则这组样本集为线性可分的; 否则为线性不可分的。(广义判别函数意义下)

- 本节考虑 “两类线性可分” 情形

5.4 感知准则函数

- 样本规范化

- 如果样本集是线性可分的，将属于 ω_2 的所有样本由 y 变成 $-y$ ，对所有 n 样本，将得到 $a^T y > 0$ 。
- 经过上述处理之后，在训练的过程中就不必考虑原来的样本类别。这一操作过程称为对样本的规范化(normalization)处理。
- 规范化增广样本：首先将所有样本写成齐次坐标形式，然后将属于 ω_2 的所有样本由 y 变成 $-y$ 。
- 后续讲解主要将集中于“规范化增广样本”。“增广”是指“齐次坐标表示”的含义，即 $y = (x^T, 1)^T \in R^{d+1}$ 。


5.4 感知准则函数—两类可分情形

• 解区与解向量


- 在线性可分的情形下，满足 $\mathbf{a}^T \mathbf{y}_i > 0, i = 1, 2, \dots, n$ 的权向量 \mathbf{a} 称为解向量。
- 权向量 \mathbf{a} 可以理解为权空间中的一点，每个样本 \mathbf{y}_i 对 \mathbf{a} 的位置均可能起到限制作用，即要求 $\mathbf{a}^T \mathbf{y}_i > 0$ 。
- 任何一个样本点 \mathbf{y}_i 均可以确定一个超平面 $H_i : \mathbf{a}^T \mathbf{y}_i = 0$ ，其法向量为 \mathbf{y}_i 。如果解向量 \mathbf{a}^* 存在，它必定在 H_i 的正侧，因为只有正侧才能满足 $(\mathbf{a}^*)^T \mathbf{y}_i > 0$ 。
- 按上述方法， n 个样本将产生 n 个超平面。每个超平面将空间分成两个半空间。如果解向量存在，它必定在所有这些正半空间的交集区域内。这个区域内的所有向量均是一个可行的解向量 \mathbf{a}^* 。

5.3 感知准则函数—两类可分情形

• 解区与解向量



未规范化



规范化

●: 第一类样本点
■: 第二类样本点

给定一个可行的 \mathbf{a} , 即可得到一个分界面


5.4 感知准则函数

- 限制解区


- 可行的解向量不是唯一的，有无穷多个。
- 经验：越靠近区域中间的解向量，越能对新的样本正确分类
- 可以引入一些条件来限制解空间
 - 比如：寻找一个单位长度的解向量 \mathbf{a} ，能最大化样本到分界面的最小距离
 - 比如：寻找一个最小长度的解向量 \mathbf{a} ，使 $\mathbf{a}^T \mathbf{y}_i \geq b > 0$ 。此时可以将 b 称为间隔 (margin)。
 - 解更加可靠，推广性更强
 - 防止算法收敛到解区的边界

5.4 感知准则函数

- 限制解区：移动一个间隔



$b=0$, 不考虑margin



$b>0$, 考虑margin

将正半空间向外
推一定的距离后
构成的交集

$$\therefore r = \frac{g(\mathbf{x})}{\|\mathbf{w}\|}$$

5.4 感知准则函数

- 感知准则函数

- 任务：设有一组样本 $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n$ ，各样本均规范化表示。我们的目的是要寻找一个解向量 \mathbf{a} ，使

$$\mathbf{a}^T \mathbf{y}_i > 0, \quad i=1,2,\dots,n$$

- 在线性可分情形下，满足上述不等式的 \mathbf{a} 是无穷多的，因此需要引入一个准则。

5.4 感知准则函数

- 感知准则函数—基本思想

- 考虑如下准则函数：

$$J_p(\mathbf{a}) = \sum_{\mathbf{y} \in Y} (-\mathbf{a}^T \mathbf{y}), \text{ 其中, } Y \text{ 为错分样本集合}$$

- 当 \mathbf{y} 被错分时, $\mathbf{a}^T \mathbf{y} \leq 0$, 则 $-\mathbf{a}^T \mathbf{y} \geq 0$ 。因此 $J_p(\mathbf{a})$ 总是大于等于0。在可分情形下, 当且仅当 Y 为空集时 $J_p(\mathbf{a})$ 将等于零, 这时将不存在错分样本。

- 因此, 目标是最小化 $J_p(\mathbf{a})$: $\min_{\mathbf{a}} J_p(\mathbf{a})$

- 这即是Frank Rosenblatt 于50年代提出的感知学习机思想。

5.4 感知准则函数

- 感知准则函数

- 考察 $J_p(\mathbf{a})$ 对 \mathbf{a} 的导数：
$$\frac{\partial J_p(\mathbf{a})}{\partial \mathbf{a}} = -\sum_{\mathbf{y} \in Y} \mathbf{y}$$

- 因此，根据梯度下降法，有如下更新准则：

$$\mathbf{a}_{k+1} = \mathbf{a}_k + \eta_k \sum_{\mathbf{y} \in Y_k} \mathbf{y}$$

这里， \mathbf{a}_{k+1} 是当前迭代的结果， \mathbf{a}_k 是前一次迭代的结果， Y_k 是被 \mathbf{a}_k 错分的样本集合， η_k 为步长因子（更新动力因子，学习率）。

5.4 感知准则函数

- 感知准则函数—算法

Batch Perceptron—基本算法

```
1  begin initialize:  $\mathbf{a}$ ,  $\eta$ , certain  $\theta$  (small value),  $k=0$ 
2    do  $k \leftarrow k+1$ 
3       $\mathbf{a} = \mathbf{a} + \eta_k \sum_{\mathbf{y} \in Y(k)} \mathbf{y}$            //  $Y(k) = Y_k$ 
4    until  $|\eta_k \sum \mathbf{y}| < \theta$ ,  $\mathbf{y} \in Y_k$       // 一个较松的停止条件
5    return  $\mathbf{a}$ 
6  end
```

- 之所以称为“batch perception”是因为在迭代过程中同时考虑多个样本。
 - 计算复杂度低，能以较快的速度收敛到极小值点
-


可变增量批处理修正方法（另一种表述形式）

Batch Variable-Increment Perceptron

```
1  begin initialize:  $\mathbf{a}$ ,  $\eta_0$ ,  $k=0$ 
2    do  $k \leftarrow k+1 \pmod n$ 
3       $Y_k = \{ \}$ ,  $j = 0$ 
4      do  $j \leftarrow j + 1$ 
5        if  $\mathbf{y}_j$  is misclassified, then append  $\mathbf{y}_j$  to  $Y_k$ 
6      until  $j = n$ 
7       $\mathbf{a} = \mathbf{a} + \eta_k \sum_{\mathbf{y} \in Y(k)} \mathbf{y}$  //发现所有错分，然后再修正
8    until  $Y_k = \{ \}$  //直到所有样本均正确分类
9    return  $\mathbf{a}$ 
10 end
```

5.4 感知准则函数

- 感知准则函数—算法解释
 - 由于所有被 \mathbf{a}_k 错分的样本必然位于以为法向量的超平面的负侧，**所以这些样本的和也必然在该侧。**
 - \mathbf{a}_{k+1} 在更新的过程中，**会向错分类样本之和靠近**，因而朝着有利的方向移动。一旦这些错分样本点穿过超平面，就正确分类了。
 - 对于线性可分的样本集，算法可以在有限步内找到最优解。
 - 收敛速度取决于初始权向量和步长



5.4 感知准则函数

- 固定增量单样本修正方法

- 每次迭代只考虑一个错分样本 \mathbf{y}^k ，梯度下降法可以写成：
 $\mathbf{a}_{k+1} = \mathbf{a}_k + \eta_k \mathbf{y}^k$ 。考虑固定增量，即令 $\eta_k = 1$ ：

Fixed-Increment Single-Sample Perceptron

```
1  begin initialize:  $\mathbf{a}$ ,  $k=0$ 
2      do  $k \leftarrow k+1 \pmod n$ 
3          if  $\mathbf{y}^k$  is misclassified by  $\mathbf{a}$ , then  $\mathbf{a} = \mathbf{a} + \mathbf{y}^k$ 
4      until all patterns properly classified
5      return  $\mathbf{a}$ 
6  end
```

“固定增量”并不改变分类决策，相当于将样本作了一个 $1/\eta_k$ 的缩放。

5.4 感知准则函数

- 可变增量单样本修正方法


- 梯度下降法可以写成: $\mathbf{a}_{k+1} = \mathbf{a}_k + \eta_k \mathbf{y}^k$

Variable-Increment Perceptron with Margin

```
1  begin initialize:  $\mathbf{a}$ , margin  $b$ ,  $\eta_0$ ,  $k=0$ 
2      do  $k \leftarrow k+1 \pmod n$ 
3          if  $\mathbf{a}^T \mathbf{y}^k \leq b$ , then  $\mathbf{a} = \mathbf{a} + \eta_k \mathbf{y}^k$  //发现一个错分, 马上修正
4      until  $\mathbf{a}^T \mathbf{y}^k > b$  for all  $k$ 
5      return  $\mathbf{a}$ 
6  end
```

5.4 感知准则函数

- 固定增量单样本修正—算法解释
 - 梯度下降： $\mathbf{a}_{k+1} = \mathbf{a}_k + \mathbf{y}^k$ 。
 - 权向量总能得到修正：
 - 由于 \mathbf{a}_k 将 \mathbf{y}^k 分错，所以 $(\mathbf{a}_k)^T \mathbf{y}^k \leq 0$ 。此时， \mathbf{a}_k 不在 \mathbf{y}^k 确定的超平面 $(\mathbf{a}_k)^T \mathbf{y}^k = 0$ 的正侧。
 - 若将 \mathbf{y}^k 加到 \mathbf{a}_k 上，则 \mathbf{a}_k 将向该超平面的正侧移动，可能会穿过这个超平面（即正确分类）。



$$(\mathbf{a}_{k+1})^T \mathbf{y}^k = (\mathbf{a}_k)^T \mathbf{y}^k + \|\mathbf{y}^k\|^2$$

$(\mathbf{a}_{k+1})^T \mathbf{y}^k$ 在原来的基础上增加了一个正数： $\|\mathbf{y}^k\|^2$

5.4 感知准则函数

- 感知准则函数—算法收敛性
 - 不失一般性，以固定增量单样本修正方法为例来说明算法的收敛性。
 - 对于权向量 \mathbf{a}_k ，如果错分某样本，则将得到一次修正。由于在分错样本时 \mathbf{a}_k 才得到修正，不妨假定只考虑由错分样本组成的序列。即是说，每次都只需利用一个分错样本来更正权向量。
 - 记错分样本序列为 $\mathbf{y}^1, \mathbf{y}^2, \dots, \mathbf{y}^k \dots$ 。考虑此情形的算法收敛性问题。

5.4 感知准则函数

- 感知准则函数—收敛性定理
 - 在样本线性可分的情形下，固定增量单样本权向量修正方法收敛，并可得到一个可行解。
- 证明思路
 - 设 \mathbf{a} 是一个解向量，只要证明 $\|\mathbf{a}_{k+1} - \mathbf{a}\| < \|\mathbf{a}_k - \mathbf{a}\|$ 即可。

5.4 感知准则函数

- 证明

- 设 \mathbf{a} 是一个解向量, 对于任意一个正的标量 α , $\alpha\mathbf{a}$ 也是一个可行解, 于是有:

$$\mathbf{a}_{k+1} - \alpha\mathbf{a} = (\mathbf{a}_k - \alpha\mathbf{a}) + \mathbf{y}^k$$

$$\|\mathbf{a}_{k+1} - \alpha\mathbf{a}\|^2 = \|\mathbf{a}_k - \alpha\mathbf{a}\|^2 + 2(\mathbf{a}_k - \alpha\mathbf{a})^T \mathbf{y}^k + \|\mathbf{y}^k\|^2$$

由于 \mathbf{y}^k 被错分, 有 $(\mathbf{a}_k)^T \mathbf{y}^k \leq 0$ 。但 $\mathbf{a}^T \mathbf{y}^k > 0$, 于是:

$$\|\mathbf{a}_{k+1} - \alpha\mathbf{a}\|^2 \leq \|\mathbf{a}_k - \alpha\mathbf{a}\|^2 - 2\alpha\mathbf{a}^T \mathbf{y}^k + \|\mathbf{y}^k\|^2$$

因此, 寻找一个合适的 α , 满足 $\|\mathbf{a}_{k+1} - \alpha\mathbf{a}\|^2 \leq \|\mathbf{a}_k - \alpha\mathbf{a}\|^2$ 即可。

- 证明 (续)

- 令 $\beta^2 = \max_{i=1,\dots,n} \|\mathbf{y}_i\|^2$, $\gamma = \min_i \mathbf{a}^T \mathbf{y}_i$

$$\|\mathbf{a}_{k+1} - \alpha \mathbf{a}\|^2 \leq \|\mathbf{a}_k - \alpha \mathbf{a}\|^2 - 2\alpha\gamma + \beta^2$$

令 $\alpha = \beta^2 / \gamma$

$$\|\mathbf{a}_{k+1} - \alpha \mathbf{a}\|^2 \leq \|\mathbf{a}_k - \alpha \mathbf{a}\|^2 - \beta^2$$

$$\|\mathbf{a}_{k+1} - \alpha \mathbf{a}\|^2 < \|\mathbf{a}_k - \alpha \mathbf{a}\|^2$$

因此，每次迭代，当前解离可行解越来越近。经过 $k+1$ 次迭代后：

$$\|\mathbf{a}_{k+1} - \alpha \mathbf{a}\|^2 \leq \|\mathbf{a}_1 - \alpha \mathbf{a}\|^2 - k\beta^2$$

由于 $\|\mathbf{a}_{k+1} - \alpha \mathbf{a}\|$ 总是非负的，所以至多经过如下次更正即可：

$$k_0 = \|\mathbf{a}_1 - \alpha \mathbf{a}\|^2 / \beta^2$$

5.5 松弛方法

- 学习准则

- 在感知函数准则中，目标函数中采用了 $-\mathbf{a}^T \mathbf{y}$ 的形式。实际上有很多其它准则也可以用于感知函数的学习。

- 线性准则: $J_p(\mathbf{a}) = \sum_{\mathbf{y} \in Y} (-\mathbf{a}^T \mathbf{y}),$
- 平方准则: $J_q(\mathbf{a}) = \sum_{\mathbf{y} \in Y} (\mathbf{a}^T \mathbf{y})^2,$

} Y 为错分样本集合

- 松弛准则: $J_r(\mathbf{a}) = \frac{1}{2} \sum_{\mathbf{y} \in Y} \frac{(\mathbf{a}^T \mathbf{y} - b)^2}{\|\mathbf{y}\|^2},$

Y 为 $\mathbf{a}^T \mathbf{y} \leq b$ 的样本集合

5.5 松弛方法

- 学习准则

- 线性准则的目标函数是分段线性的，因此其梯度是不连续的。
- 平方准则的梯度是连续的，但目标函数过于平滑，收敛速度很慢（达到目标函数为零的区域的路径很平缓）。同时，目标函数过于受到最长样本的影响。
- $J_r(a)$ 则避免了这些缺点。
- $J_r(a)$ 最终达到零。此时对所有的 y ， $\mathbf{a}^T \mathbf{y} > b$ ，则意味着集合 Y 是空集。

5.5 松弛方法

- 学习：训练

- 梯度：
$$\frac{\partial J_r(\mathbf{a})}{\partial \mathbf{a}} = \sum_{\mathbf{y} \in Y} \frac{\mathbf{a}^T \mathbf{y} - b}{\|\mathbf{y}\|^2} \mathbf{y}$$

- 梯度下降准则：
$$\mathbf{a}_{k+1} = \mathbf{a}_k - \eta_k \sum_{\mathbf{y} \in Y} \frac{\mathbf{a}^T \mathbf{y} - b}{\|\mathbf{y}\|^2} \mathbf{y}$$

5.5 松弛方法

Batch Relaxation with Margin

```
1  begin initialize:  $\mathbf{a}$ ,  $b$   $\eta_0$ ,  $k=0$ 
2      do  $k \leftarrow k+1 \pmod n$ 
3           $Y_k = \{ \}$ ,  $j = 0$ 
4          do  $j \leftarrow j + 1$ 
5              if  $\mathbf{a}^T \mathbf{y}_j \leq b$ , then append  $\mathbf{y}_j$  to  $Y_k$  //如果错分
6          until  $j = n$ 
7           $\mathbf{a}_{k+1} = \mathbf{a}_k - \eta_k \sum_{\mathbf{y} \in Y} ((\mathbf{a}^T \mathbf{y} - b) / \|\mathbf{y}\|^2) \cdot \mathbf{y}$ ,
8      until  $Y_k = \{ \}$ 
9      return  $\mathbf{a}$ 
10 end
```

5.5 松弛方法

- 单样本松弛算法

- 可假定序列中每个样本都为错分样本（此时为 $\mathbf{a}^T \mathbf{y} \leq b$ ），记为： $\mathbf{y}^1, \mathbf{y}^2, \dots, \mathbf{y}^k \dots$ 。
- 仍可假定在梯度下降过程中，更新步长 η_k 为常数，且 $\eta_k = \eta$ 。
- 更新准则：

$$\mathbf{a}_{k+1} = \mathbf{a}_k - \eta_k \frac{\mathbf{a}_k^T \mathbf{y}^k - b}{\|\mathbf{y}^k\|^2} \mathbf{y}^k = \mathbf{a}_k - \eta_k \frac{\mathbf{a}_k^T \mathbf{y}^k - b}{\|\mathbf{y}^k\|} \frac{\mathbf{y}^k}{\|\mathbf{y}^k\|}$$

5.5 松弛方法

- 单样本松弛算法

Single Sample Relaxation with Margin

```
1  begin initialize:  $\mathbf{a}$ , margin  $b$ ,  $\eta$ ,  $k=0$ 
2    do  $k \leftarrow k+1 \pmod{n}$ 
3      if  $\mathbf{a}^T \mathbf{y}^k \leq b$ , then  $\mathbf{a} = \mathbf{a} - \left( \eta (\mathbf{a}^T \mathbf{y}^k - b) / \|\mathbf{y}^k\|^2 \right) \cdot \mathbf{y}^k$ 
4    until  $\mathbf{a}^T \mathbf{y}^k > b$  for all  $\mathbf{y}^k$ 
5    return  $\mathbf{a}$ 
6  end
```

5.5 松弛方法

• 几何解释

点 \mathbf{a}_k 到超平面 $\mathbf{a}^T \mathbf{y}^k = b$ 的距离:


$$r_k = \frac{b - \mathbf{a}_k^T \mathbf{y}^k}{\|\mathbf{y}^k\|}$$

点 \mathbf{a}_k 沿着单位向量方向 $\mathbf{y}^k / \|\mathbf{y}^k\|$ 移动其 ηr_k 倍的距离, 得到新的 \mathbf{a}_{k+1} 。

根据更新准则, 有:

$$(\mathbf{a}_{k+1})^T \mathbf{y}^k - b = (1 - \eta) ((\mathbf{a}_k)^T \mathbf{y}^k - b)$$

(离超平面更近了)



5.5 松弛方法


• 几何解释

如果 $\eta=1$ ， \mathbf{a}_k 将直接移动到该超平面。由于 \mathbf{y}^k 被错分引起的压力 “ $\mathbf{a}^T \mathbf{y}^k < b$ ” 被释放，所以称为松弛方法。

如果 $\eta < 1$ ，仍有 $(\mathbf{a}_{k+1})^T \mathbf{y}^k < b$ 。此时尽管 \mathbf{y}^k 仍被错分，但 \mathbf{a}_{k+1} 比 \mathbf{a}_k 更好。因为 \mathbf{a}_{k+1} 离跨过超平面更近。此时，称为软松弛。

如果 $\eta > 1$ ， \mathbf{a}_{k+1} 将跨过超平面， \mathbf{y}^k 将被正确分类。称为超松弛。

实际中取 $0 < \eta < 2$ 。



5.5 松弛方法

- 收敛性—考虑单样本松弛法

- 设 \mathbf{a} 是一个解向量, 因此对任意 \mathbf{y}_i , 有 $\mathbf{a}^T \mathbf{y}_i > b$, 于是:

$$\|\mathbf{a}_{k+1} - \mathbf{a}\|^2 = \|\mathbf{a}_k - \mathbf{a}\|^2 - 2\eta \frac{b - \mathbf{a}_k^T \mathbf{y}^k}{\|\mathbf{y}^k\|^2} (\mathbf{a} - \mathbf{a}_k)^T \mathbf{y}^k + \eta^2 \frac{(b - \mathbf{a}_k^T \mathbf{y}^k)^2}{\|\mathbf{y}^k\|^2}$$

$$(\mathbf{a} - \mathbf{a}_{k+1})^T \mathbf{y}^k = \mathbf{a}^T \mathbf{y}^k - \mathbf{a}_{k+1}^T \mathbf{y}^k > b - \mathbf{a}_{k+1}^T \mathbf{y}^k$$

$$\Rightarrow \|\mathbf{a}_{k+1} - \mathbf{a}\|^2 < \|\mathbf{a}_k - \mathbf{a}\|^2 - \eta(2 - \eta) \frac{(b - \mathbf{a}_k^T \mathbf{y}^k)^2}{\|\mathbf{y}^k\|^2}$$

$$\Rightarrow \|\mathbf{a}_{k+1} - \mathbf{a}\|^2 < \|\mathbf{a}_k - \mathbf{a}\|^2 \quad (\text{由于 } 0 < \eta < 2)$$

5.6 最小平方误差 (MSE) 准则函数

- 动机

- 对两类分问题，感知准则函数是寻找一个解向量 \mathbf{a} ，对所有样本 \mathbf{y}_i ，满足 $\mathbf{a}^T \mathbf{y}_i > 0, i=1,2,\dots,n$ 。或者说，求解一个不等式组，使满足 $\mathbf{a}^T \mathbf{y}_i > 0$ 的数目最大，从而错分样本最少。
- 现在将不等式改写为等式形式：

$$\mathbf{a}^T \mathbf{y}_i = b_i > 0$$

其中， b_i 是任意给定的正常数，通常取 $b_i = 1$ ，或者 $b_i = n_j / n$ 。其中， $n_j, j = 1 \text{ or } 2$ ，为属于第 j 类样本的总数，且 $n_1 + n_2 = n$ 。

5.6 MSE 准则函数

- 方法

- 可得一个线性方程组（例如，齐次表示）：

$$\begin{pmatrix} y_{10} & y_{11} & \cdots & y_{1d} \\ y_{20} & y_{21} & \cdots & y_{2d} \\ \vdots & \vdots & & \vdots \\ \vdots & \vdots & & \vdots \\ y_{n0} & y_{n1} & \cdots & y_{nd} \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ \vdots \\ a_d \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ \vdots \\ b_d \end{pmatrix} \quad \text{or} \quad \mathbf{Y}\mathbf{a} = \mathbf{b}$$

- 如果 \mathbf{Y} 可逆，则 $\mathbf{a} = \mathbf{Y}^{-1}\mathbf{b}$
- 但通常情形下， $n \gg d + 1$ ，因此，考虑定义一个误差向量：
 $\mathbf{e} = \mathbf{Y}\mathbf{a} - \mathbf{b}$ ，并使误差向量最小。

5.6 MSE 准则函数

- 平方误差准则函数： $J_s(\mathbf{a}) = \|\mathbf{e}\|^2 = \|\mathbf{Y}\mathbf{a} - \mathbf{b}\|^2 = \sum_{i=1}^n (\mathbf{a}^T \mathbf{y}_i - b_i)^2$

- 偏导数：
$$\frac{\partial J_s(\mathbf{a})}{\partial \mathbf{a}} = \sum_{i=1}^n 2(\mathbf{a}^T \mathbf{y}_i - b_i) \mathbf{y}_i = 2\mathbf{Y}^T (\mathbf{Y}\mathbf{a} - \mathbf{b})$$

- 令偏导数为零，得：

$$\mathbf{Y}^T \mathbf{Y} \mathbf{a} = \mathbf{Y}^T \mathbf{b}, \Rightarrow \mathbf{a} = (\mathbf{Y}^T \mathbf{Y})^{-1} \mathbf{Y}^T \mathbf{b} = \mathbf{Y}^+ \mathbf{b}$$

其中， \mathbf{Y}^+ 即为 \mathbf{Y} 的伪逆。

- 实际计算（正则化技术）：
$$\mathbf{Y}^+ \approx (\mathbf{Y}^T \mathbf{Y} + \varepsilon \mathbf{I})^{-1} \mathbf{Y}^T \Big|_{\varepsilon \rightarrow 0}$$

（即回归分析方法）

5.6 MSE 准则函数

- 梯度下降法

- 计算伪逆需要求矩阵的逆，计算复杂度高。如果原始样本的维数很高，比如 $d > 5000$ ，将十分耗时。

- 采用梯度下降法： $\mathbf{a}_{k+1} = \mathbf{a}_k + \eta_k \mathbf{Y}^T (\mathbf{b} - \mathbf{Y}\mathbf{a}_k)$

- 梯度下降法得到的 \mathbf{a}_{k+1} 将收敛于一个解，该解满足方程： $\mathbf{Y}^T (\mathbf{b} - \mathbf{Y}\mathbf{a}) = 0$

- 也可以采用序列更新方法，此方法需要的计算存储量会更小：

$$\mathbf{a}_{k+1} = \mathbf{a}_k + \eta_k (b_k - (\mathbf{a}_k)^T \mathbf{y}^k) \mathbf{y}^k$$

（此时考虑单个样本对误差的贡献）

5.6 MSE 准则函数

- Widrow-Hoff方法（序列最小平方更新方法）

Widrow-Hoff (Least mean squared) Approach

```
1  begin initialize: a, b,  $\eta$ , threshold  $\theta$ ,  $k=0$ 
2    do  $k \leftarrow k+1 \pmod n$ 
3      a = a +  $\eta_k (b_k - (\mathbf{a}_k)^T \mathbf{y}^k) \mathbf{y}^k$ 
4    until  $\| (b_k - (\mathbf{a}_k)^T \mathbf{y}^k) \mathbf{y}^k \| < \theta$ 
5    return a
6  end
```

注： \mathbf{y}^k 为使 $(\mathbf{a}_k)^T \mathbf{y}^k \neq b_k$ 的样本，因为相等时对更新无贡献

5.6 MSE 准则函数


- Widrow-Hoff方法 vs 松弛算法

- 松弛算法是一种错误更正方法，要求 $\mathbf{a}^T \mathbf{y}^k > b$ for all \mathbf{y}^k 。
- Widrow-Hoff 要求更正不相等情形： $(\mathbf{a}_k)^T \mathbf{y}^k \neq b_k$ 。但是，**实际上，满足 $(\mathbf{a}_k)^T \mathbf{y}^k = b_k$ 几乎是不可能的**。因此，迭代将会无穷次进行下去。所以要求 η_k 需要随着 k 的增加而逐渐减小，以保证算法的收敛性。一般来讲，实际计算中取： $\eta_k = \eta_1 / k$ 。

5.6 MSE 准则函数

- **Widrow-Hoff方法 vs 感知器准则**
 - 相对于感知器准则，**最小平方准则方法可能并不收敛于可分超平面，即使该平面是存在的。**
 - MSE方法的本质是最小化样本至超平面的距离的平方和。

将超平面旋转一个角度，不会改变距离平方和



5.7 Ho-Kashyap 方法

- Ho-Kashyap 方法

- MSE算法上最小化 $\|\mathbf{Y}\mathbf{a}-\mathbf{b}\|^2$ ，所得到的最优解并不需要位于可分超平面上。
- 如果训练样本是线性可分的，则可找到一个权向量 \mathbf{a} ，对所有样本，均有 $\mathbf{a}^T \mathbf{y}_i > 0$ 。换句话说，一定存在一个 \mathbf{a} 和 \mathbf{b} ，使

$$\mathbf{Y}\mathbf{a} = \mathbf{b} > 0$$

但是，事先并不知道 \mathbf{b} 。因此，MSE准则函数可以更新为：

$$J_s(\mathbf{a}, \mathbf{b}) = \|\mathbf{Y}\mathbf{a}-\mathbf{b}\|^2$$

注：直接优化 $J_s(\mathbf{a}, \mathbf{b})$ 将导致平凡解，所以需要给 \mathbf{b} 加一个 $\mathbf{b}>0$ 的约束条件。此时， \mathbf{b} 可以解释为margin。

5.7 Ho-Kashyap 方法

- 梯度下降法

- 梯度

$$\frac{\partial J_s(\mathbf{a}, \mathbf{b})}{\partial \mathbf{a}} = 2\mathbf{Y}^T(\mathbf{Y}\mathbf{a} - \mathbf{b}), \quad \frac{\partial J_s(\mathbf{a}, \mathbf{b})}{\partial \mathbf{b}} = -2(\mathbf{Y}\mathbf{a} - \mathbf{b})$$

对 \mathbf{a} 而言，总有 $\mathbf{a} = \mathbf{Y}^+\mathbf{b}$ ，其中 \mathbf{Y}^+ 为 \mathbf{Y} 的伪逆。

对 \mathbf{b} ，需要同时满足约束条件 $\mathbf{b} > \mathbf{0}$ 。梯度更新：

$$\mathbf{b}_{k+1} = \mathbf{b}_k - \eta_k \frac{\partial J_s(\mathbf{a}, \mathbf{b})}{\partial \mathbf{b}}$$

由于 \mathbf{b}_k 总是大于零，要使 \mathbf{b}_{k+1} 也大于零，可以要求 $\partial J_s(\mathbf{a}, \mathbf{b}) / \partial \mathbf{b}$ 为负。

• 梯度下降法

– \mathbf{b} 的梯度下降:

$$\mathbf{b}_1 > \mathbf{0}, \quad \mathbf{b}_{k+1} = \mathbf{b}_k - \eta_k \left[\frac{\partial J_s(\mathbf{a}, \mathbf{b})}{\partial \mathbf{b}} - \left| \frac{\partial J_s(\mathbf{a}, \mathbf{b})}{\partial \mathbf{b}} \right| \right] \quad (\leq 0)$$

元素取绝对值

– 更新 \mathbf{a} 和 \mathbf{b} : $\mathbf{a}_k = \mathbf{Y}^+ \mathbf{b}_k$

$$\mathbf{b}_1 > \mathbf{0}, \quad \mathbf{b}_{k+1} = \mathbf{b}_k + 2\eta_k \mathbf{e}_k^+$$

$$\text{其中, } \mathbf{e}_k^+ = \frac{1}{2} \left((\mathbf{Y}\mathbf{a}_k - \mathbf{b}_k) + |\mathbf{Y}\mathbf{a}_k - \mathbf{b}_k| \right), \quad \because \frac{\partial J_s(\mathbf{a}, \mathbf{b})}{\partial \mathbf{b}} = -2(\mathbf{Y}\mathbf{a} - \mathbf{b})$$

为了防止 \mathbf{b} 收敛于 $\mathbf{0}$ ，可以让 \mathbf{b} 从一个非负向量（ $\mathbf{b}_1 > \mathbf{0}$ ）开始进行更新。

由于要求 $\partial J_s(\mathbf{a}, \mathbf{b}) / \partial \mathbf{b}$ 等于 $\mathbf{0}$ ，在开始迭代时可令 $\partial J_s(\mathbf{a}, \mathbf{b}) / \partial \mathbf{b}$ 的元素为正的分量等于零，从而加快收敛速度。

5.7 Ho-Kashyap 方法

Ho-Kashyap Algorithm

```
1  begin initialize: a, b,  $\eta_0 < 1$ ,  $k=0$ , threshold  $b_{\min}$ ,  $k_{\max}$ 
2      do  $k \leftarrow k+1 \pmod n$ 
3          e  $\leftarrow \mathbf{Y}\mathbf{a} - \mathbf{b}$ 
4           $\mathbf{e}^+ \leftarrow 1/2(\mathbf{e} + \text{abs}(\mathbf{e}))$ 
5          b  $\leftarrow \mathbf{b} + 2 \eta_k \mathbf{e}^+$ 
6          a  $= \mathbf{Y}^+\mathbf{b}$ 
7          if  $\text{abs}(\mathbf{e}) \leq b_{\min}$ , then return a, b and exit
8      until  $k = k_{\max}$ 
9      print “No solution found!”
10 end
```

5.7 Ho-Kashyap 方法

- Ho-Kashyap算法

- 由于权向量序列 $\{\mathbf{a}_k\}$ 完全取决于 $\{\mathbf{b}_k\}$ ，因此本质上讲 Ho-Kashyap 算法是一个生成margin 序列 $\{\mathbf{b}_k\}$ 的方法。
- 由于初始 $\mathbf{b}_1 > \mathbf{0}$ ，且更新因子 $\eta > 0$ ，因此 \mathbf{b}_k 总是大于 $\mathbf{0}$ 。
- 对于更新因子 $0 < \eta \leq 1$ ，如果问题线性可分，则总能找到元素全为正的 \mathbf{b} 。
- 如果 $\mathbf{e}_k = \mathbf{Y}\mathbf{a}_k - \mathbf{b}_k$ 全为 0，此时， \mathbf{b}_k 将不再更新，因此获得一个解。如果 \mathbf{e}_k 有一部分元素小于0，则可以证明该问题不是线性可分的*。

*证明见：Richard O. Duda, Peter E. Hart, David G. Stork, Pattern Classification, 2nd Edition, John Wiley, 2001. page: 251-253

5.8 多类线性判别函数

- 对 c 类分类问题

- 对于 c 类分类问题:

- 设 $g_i(\mathbf{x})$, $i=1,2,\dots,c$, 表示每个类别对应的判别函数

- 线性机器的决策规则:

- 如果 $g_i(\mathbf{x}) \geq g_j(\mathbf{x})$, $\forall j \neq i$, 则 \mathbf{x} 被分为第 ω_i 类。

- 考虑多类线性可分的情形, 对规范化增广样本表示方法, 此时决策规则为:

$$\mathbf{a}_i^T \mathbf{y} \geq \mathbf{a}_j^T \mathbf{y}, \quad \forall j \neq i, \text{ 则 } \mathbf{y} \text{ 被分为第 } i \text{ 类}$$

• 方法一：MSE多类扩展

- 可以直接采用 c 个两类分类器的组合，且这种组合具有与两类分类问题类似的代数描述形式
- 线性变换(注，此处不必采用规范化增广坐标表示)：

$$\mathbf{y} = \mathbf{W}^T \mathbf{x} + \mathbf{b}, \quad \mathbf{W} \in R^{d \times c}, \mathbf{b} \in R^c$$

- 决策准则： if $j = \arg \max (\mathbf{W}^T \mathbf{x} + \mathbf{b})$, then $\mathbf{x} \in \omega_j$
- 回归值的构造：

比如：设第1,2个样本属于第一类，则 $\mathbf{y}_1 = \mathbf{y}_2 = [1, 0, 0, \dots, 0]^T$

$$\mathbf{Y} = \begin{pmatrix} 1 & 1 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix} = [\mathbf{y}_1, \mathbf{y}_2, \cdots, \mathbf{y}_n] \in R^{c \times n}$$

• 方法一：MSE多类扩展

— 目标函数：

$$\min_{\mathbf{W}, \mathbf{b}} \sum_{i=1}^n \left\| \mathbf{W}^T \mathbf{x} + \mathbf{b} - \mathbf{y}_i \right\|_2^2$$

$$\text{令： } \hat{\mathbf{W}} = \begin{pmatrix} \mathbf{W} \\ \mathbf{b}^T \end{pmatrix} \in R^{(d+1) \times c}, \quad \hat{\mathbf{x}} = \begin{pmatrix} \mathbf{x} \\ 1 \end{pmatrix} \in R^{d+1}, \quad \hat{\mathbf{X}} = (\hat{\mathbf{x}}_1, \hat{\mathbf{x}}_2, \dots, \hat{\mathbf{x}}_n) \in R^{(d+1) \times n}$$



$$\sum_{i=1}^n \left\| \mathbf{W}^T \mathbf{x} + \mathbf{b} - \mathbf{y}_i \right\|_2^2 = \left\| \hat{\mathbf{W}}^T \hat{\mathbf{X}} - \mathbf{Y} \right\|_F^2 \quad (\|\cdot\|_F \text{ 为 Frobenius 范数})$$



$$\min_{\hat{\mathbf{W}}} \left\| \hat{\mathbf{W}}^T \hat{\mathbf{X}} - \mathbf{Y} \right\|_F^2$$



$$\hat{\mathbf{W}} = \left(\hat{\mathbf{X}} \hat{\mathbf{X}}^T \right)^{-1} \hat{\mathbf{X}} \mathbf{Y}^T \in R^{(d+1) \times c} \quad \hat{\mathbf{W}} = \left(\hat{\mathbf{X}} \hat{\mathbf{X}}^T + \lambda \mathbf{I} \right)^{-1} \hat{\mathbf{X}} \mathbf{Y}^T \in R^{(d+1) \times c}$$

λ : 一个小正数

• 方法二：感知器准则扩展方法—逐步修正(不讲-自学)

- 目标：一次性学习出 c 个权重向量（以下采用规范化增广样本表示）
- S_1 : 设置任意的初始权重向量 $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_c$
- S_2 : 考察某个属于第 i 类的样本 \mathbf{y}^k :
 - 如果 $(\mathbf{a}_i)^T \mathbf{y}^k > (\mathbf{a}_j)^T \mathbf{y}^k$ ，对任意 $j \neq i$ 均成立，则所有权向量不变；
 - 如果存在 j 使 $(\mathbf{a}_i)^T \mathbf{y}^k \leq (\mathbf{a}_j)^T \mathbf{y}^k$ ，则可以选择一个 j （比如使 $(\mathbf{a}_j)^T \mathbf{y}^k$ 最大者），对权值分量进行修正：

$$\left\{ \begin{array}{l} \mathbf{a}_i(k+1) = \mathbf{a}_i(k) + \eta_k \mathbf{y}^k \\ \mathbf{a}_j(k+1) = \mathbf{a}_j(k) - \eta_k \mathbf{y}^k \\ \mathbf{a}_m(k+1) = \mathbf{a}_m(k), \quad m \neq i, j \end{array} \right\} \text{ 相当于将样本 } [(\mathbf{y}^k)^T, (-\mathbf{y}^k)^T] \text{ 错分}$$

- S_3 : 如果对所有样本均正确分类，则停止；否则考察另一个样本。

- **方法三：Kelser 构造**（注：此处采用规范化增广样本表示）（不讲-自学）

- 设计一个两类分类线性分类器。
- 解决这一问题的思路是：将 $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_c$ 组合成一个长向量，同时构造新的训练样本。

$$\mathbf{a}_1^T \mathbf{y} > \mathbf{a}_j^T \mathbf{y}, j = 2, 3, \dots, c$$

- 比如，如果样本 \mathbf{y} 属于第一类，则有

此时，可构造如下 $c-1$ 个新样本：

$$\boldsymbol{\eta}_{12} = \begin{pmatrix} \mathbf{y} \\ -\mathbf{y} \\ \mathbf{0} \\ \vdots \\ \mathbf{0} \end{pmatrix}, \quad \boldsymbol{\eta}_{13} = \begin{pmatrix} \mathbf{y} \\ \mathbf{0} \\ -\mathbf{y} \\ \vdots \\ \mathbf{0} \end{pmatrix}, \quad \dots, \quad \boldsymbol{\eta}_{1c} = \begin{pmatrix} \mathbf{y} \\ \mathbf{0} \\ \mathbf{0} \\ \vdots \\ -\mathbf{y} \end{pmatrix}$$

$$\begin{matrix} \uparrow & \uparrow & \uparrow \\ \mathbf{a}_1^T \mathbf{y} > \mathbf{a}_2^T \mathbf{y} & \mathbf{a}_1^T \mathbf{y} > \mathbf{a}_3^T \mathbf{y} & \mathbf{a}_1^T \mathbf{y} > \mathbf{a}_c^T \mathbf{y} \end{matrix}$$

- 方法三：Kelser 构造

- 因此，对 n 个样本来讲，由于有 c 个类别，一共可构造出 $(c-1)n$ 个新样本，它们的维数为 $c(d+1)$ (考虑线性齐次坐标)，这样就生成了一个新的两类分类问题。
- 如果线性可分，则需要找一个权向量 \mathbf{a} 使

$$\mathbf{a}^T \boldsymbol{\eta}_{ij} > 0, j \neq i$$

$$\text{其中, } \mathbf{a} = \begin{pmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \\ \vdots \\ \mathbf{a}_c \end{pmatrix}.$$

$$\text{比如: } \mathbf{a}_1^T \mathbf{y} > \mathbf{a}_j^T \mathbf{y} \Leftrightarrow \mathbf{a}^T \boldsymbol{\eta}_{1j} > 0$$

- **方法三：Kelser 构造**

- 优点：

- 可以将一个多类问题转化为一个两类分类问题，便于采用现有的两类分类器构造方法
 - 由此获得的一个多类线性分类器可以保证不会出现歧义区域。

- 缺点：

- 缺点十分明确：增加了样本的规模，增大了样本空的维数，对大数据处理极度不利。

5.9 本章小结

- 概念

- 判别函数、线性判别函数、广义线性判别函数、可分性、分界面、决策规则、点到超平面的距离、规范化增广样本表示、多类分类

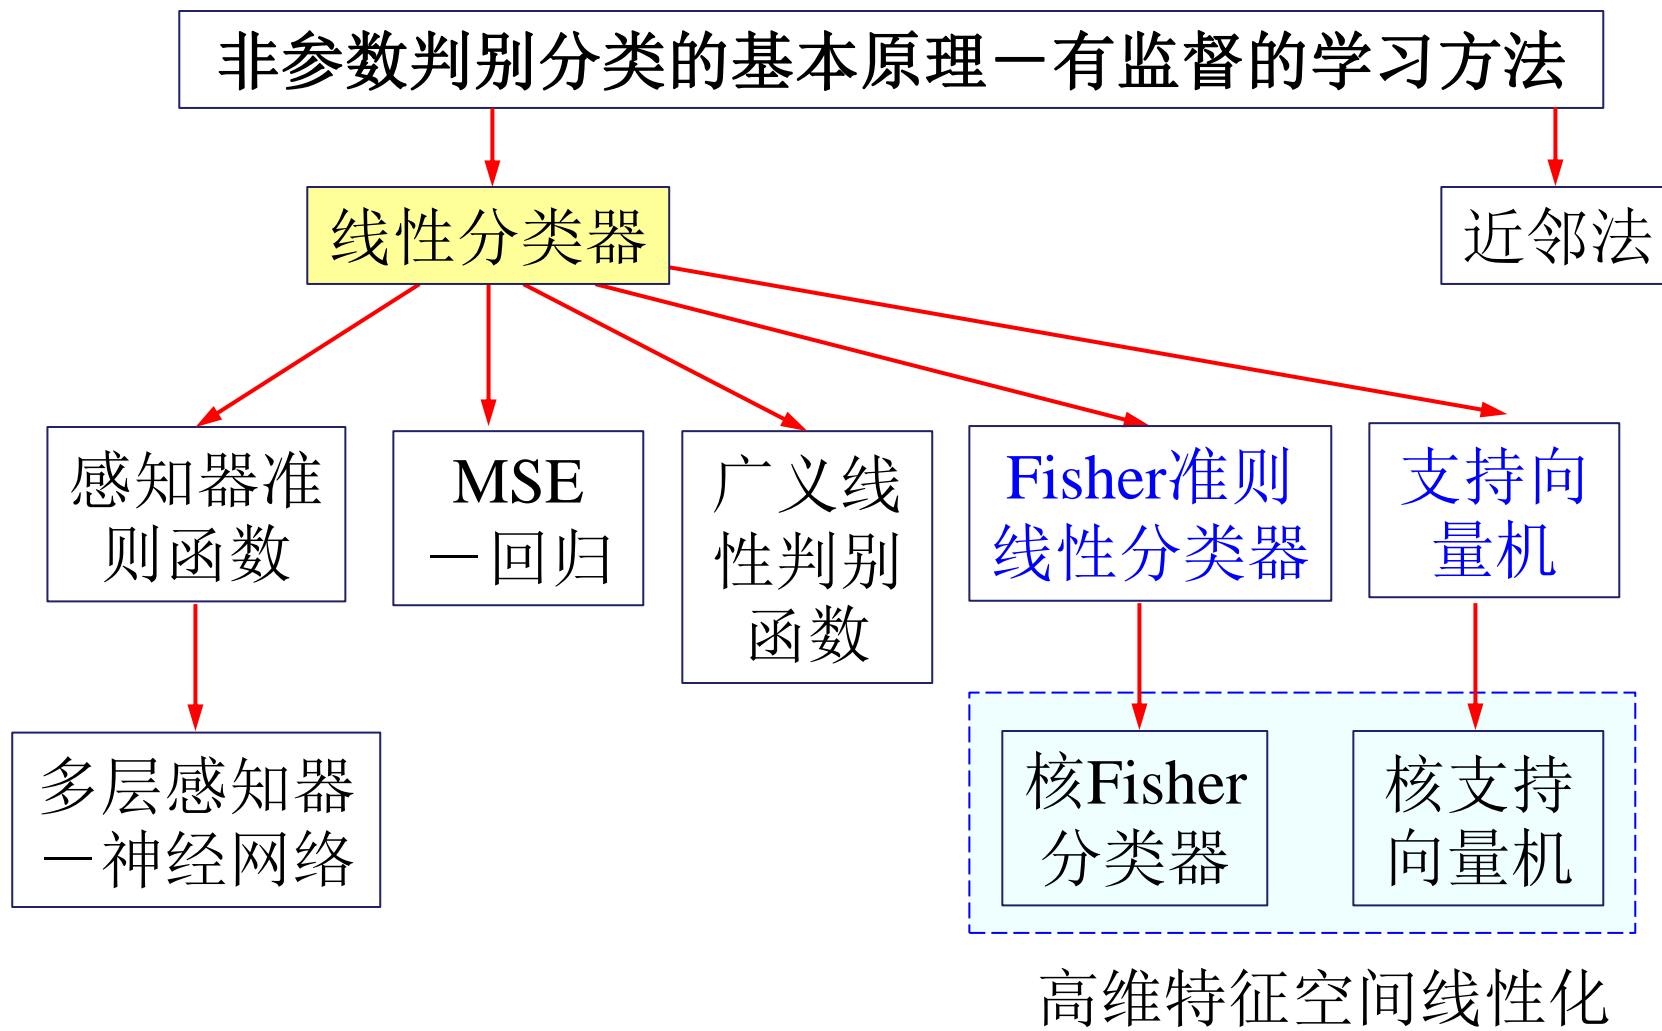
- 线性判别函数

- 感知准则函数、松弛感知准则函数、平方误差准则函数

- 算法

- 感知准则函数的批量更新方法、感知准则函数的单样本更新方法、松弛感知准则函数单样本更新方法、MSE梯度下降法、Ho-Kashyap方法、多类扩展方法

5.9 本章小结



下次课内容

- 神经网络基础
 - 发展历史
 - 网络结构
- 基本模型
 - 单层感知器、多层感知器、反向传播算法等

Thank All of You!
(Questions?)

向世明

smxiang@nlpr.ia.ac.cn

people.ucas.ac.cn/~xiangshiming

时空数据分析与学习课题组 (STDAL)

中科院自动化研究所· 模式识别国家重点实验室